

Claude

+

新增

📁

專案

🔗

成品

<>

程式碼

📄

自訂

對話與任務

建立領域專屬RAG諮詢系統

Pine Script trading Indicator review

本地部署領域專家AI系統實作

Monetizing local AI development v1

本地開源AI生成LINE貼圖環境搭建

識別照片中的書籍

台中鐵皮廠房租金計算

改善睡眠品質和減少夢話

认识Claude

🔧

提高睡覺品質，降低

88

🔍

建立領域專屬RAG諮詢系統

Free 方案 · 升級 ×

分享

RAG ~ 數位員工

我的開發環境是AMD Ryzen AI Max+ 395 (128GB)的Windows11上有LM Studio 可以運行 Qwn3.6-35B-A3B + LINUX(VM) 的 Hermes Agent 運行的環境

我要如何在此基礎上實作出 一個專屬領域的諮詢專家如 產品客服/特定領域法律諮詢/...

讀系統只在特定可擴充資料來源的知識庫內進行搜索與回覆

現在規劃出在VM內小白也能實作的完整步驟給我

讀取記憶, 已搜尋網路, 已更新記憶

架構規劃：本地端專屬領域 RAG 諮詢專家

你的硬體資源很夠（128GB 統一記憶體 + 35B 模型），最務實的做法是不要自己刻 RAG pipeline，而是用一套成熟的開源 RAG 管理平台，把 LM Studio 當作「大腦」（推論引擎），VM 裡跑平台本體負責「知識庫管理 + 檢索 + 限定回答範圍」。這樣小白也能靠點滑鼠完成 90% 的設定。

推薦工具：AnythingLLM（Docker 一鍵部署，內建向量資料庫，原生支援 LM Studio 作為 LLM 與 Embedding 來源，並有「只依資料庫回答」的 Query Mode）。

整體架構：

[Windows 11 主機]

LM Studio (Qwen3.6-35B-A3B 對話模型 + 一個 Embedding 模型)

→ 對區網開放 API (port 1234)

↓ 網路連線

[Linux VM]

Docker → AnythingLLM 容器

→ 瀏覽器管理介面 (port 3001)

→ 每個 Workspace = 一個獨立領域專家 (產品客服 / 法律諮詢 / ...)

→ 各自上傳知識庫文件，互不干擾

Step 1 | Windows：讓 LM Studio 對外提供服務

1. 開啟 LM Studio → 左側 Developer / Server 頁籤。

2. 載入 Qwn3.6-35B-A3B（你已在用的對話模型）。

3. 另外在 LM Studio 的模型庫裡搜尋並下載一個 Embedding 模型（例如 nomic-embed-text 或 bge-m3），一併載入。LM Studio 的本地伺服器同時支援 Chat 和 Embedding 兩種端點。

4. 在 Server 設定裡把“Serve on Local Network”（監聽區網）打開，port 預設 1234。

5. 按 Start Server。

6. 打開 Windows 終端機執行 ipconfig，記下主機在區網內的 IP（例如 192.168.1.50）。這組 192.168.1.50:1234 就是等一下 VM 要連的位址。

7. 確認 Windows 防火牆允許 1234 port 的輸入連線（第一次啟動 Server 時通常會跳出防火牆詢問視窗，允許即可）。

Step 2 | 確認 VM 網路能連到 Windows 主機

在 VM 裡開終端機測試：

bash

curl http://192.168.1.50:1234/v1/models

（IP 換成你自己記下的）如果回傳一段 JSON 列出模型名稱，代表 VM 已經能打到 LM Studio。如果連不上，通常是 VM 網路模式要從 NAT 改成「橋接」，或防火牆擋住，先排除這一步再往下走。

Step 3 | VM 內安裝 Docker

bash

sudo apt update

curl -fsSL https://get.docker.com | sudo sh

sudo usermod -aG docker \$USER

newgrp docker

Step 4 | 部署 AnythingLLM

bash

mkdir -p ~/anythingllm-data

docker run -d -p 3001:3001 \

--name anythingllm \

-v ~/anythingllm-data:/app/server/storage \

-e STORAGE_DIR="/app/server/storage" \

mintplexlabs/anythingllm

啟動後，用瀏覽器開 http://<VM的IP>:3001（或 localhost:3001，看你怎麼存取這台 VM）。第一次會要你建立管理員帳號。

Step 5 | 把 LM Studio 接進 AnythingLLM

- 1. 進入 Settings→LLM Preference。
- 2. Provider 選 **LM Studio**。
- 3. Base URL 填 `http://192.168.1.50:1234/v1` (你 Step 1 記下的 IP)。
- 4. 選擇 Qwen3.6-35B-A3B 作為模型。
- 5. 再到 Settings→Embedding Preference，Provider 一樣選 **LM Studio**，指到同一個 Base URL，選你載入的 embedding 模型。
- 6. 儲存後回主頁，通常會有連線測試，確認綠燈。

Step 6 | 建立第一個「領域專家」

AnythingLLM 的 **Workspace** (工作區) 就是你要的「專屬領域專家」單位——每個 workspace 有自己獨立的知識庫、獨立的 system prompt、互不干擾。

- 1. 點 **New Workspace**，命名例如「產品客服」。
- 2. 進去後點 **Upload / 上傳文件**，把 PDF、Word、txt、markdown 或網址貼進去，讓它建立索引 (embedding)。之後要擴充資料，隨時回這裡再上傳新文件即可，不用重建整個系統。
- 3. 進入該 workspace 的 **Settings→Chat Settings**：
 - **Chat Mode** 選「**Query**」(不是 Chat)：Query 模式代表「只根據檢索到的文件內容回答，找不到相關內容就明確說沒有資料」，這正是你要的「只在特定知識庫內搜索回覆」。
 - 可再加一段 **System Prompt**，例如：

你是一位產品客服專家，只能根據提供的知識庫內容回答問題。若知識庫中找不到相關資訊，請明確告知使用者「目前知識庫中沒有相關資料」，不可自行推測或使用知識庫以外的一般知識回答。
- 4. 調整 **Similarity Threshold** (相似度門檻) 與 **Top-N chunks** (檢索片段數)：門檻拉高可以減少「答非所問」，但太高會變成常常查無資料，建議先用預設值測試幾輪再微調。

Step 7 | 測試與擴充

- 直接在該 workspace 的聊天視窗測試幾個你知道答案 (在文件裡) 跟不知道答案 (不在文件裡) 的問題，確認它「有依據就答、沒依據就拒答」的行為正確。
- 之後要新增第二個領域 (例如「法律諮詢」)，重複 Step 6：新建一個 workspace，上傳該領域專屬文件，各 workspace 完全獨立、不會互相污染知識來源。
- 知識庫要擴充，就直接進對應 workspace 上傳新檔案，AnythingLLM 會自動重新索引，不需要碰任何程式碼。

這套流程全程用瀏覽器介面操作，沒有需要寫程式的地方。你的 **Hermes Agent** 之後如果想接手做「更主動的任務執行」(而不只是被動問答)，AnythingLLM 也提供 **Developer API**，可以讓 **Hermes Agent** 呼叫它的 workspace 當作查詢工具——但那是進階整合，建議先把上面這套基礎 RAG 跑通、測試回答品質穩定後再考慮。

需要我把這份步驟整理成一份可離線保存的文件 (Markdown 或 Word) 嗎？

上述 RAG 的區塊 可以使用 llam-wiki 取代嗎

已搜尋網路 >

可以取代一部分，但不建議在「對外客服 / 法律諮詢」場景完全取代 RAG。比較合理的做法是兩者混用。

llm-wiki 是什麼

這是 Karpathy 在 2026 年 4 月提出的做法。LLM agent 會逐步建立並維護一份由 markdown 檔組成的結構化 wiki，不再每次從原始文件檢索。常見結構是 `[raw/ 放原始資料、wiki/ 放 LLM 整理出的頁面，再加一份 schema 檔 ( 如 CLAUDE.md ) 說明規則`。差別在於「整合知識」發生在匯入時，而不是每次提問時。`[ ai-builder-club is-a`

比較

	RAG (AnythingLLM)	llm-wiki
知識整理時機	查詢時才檢索片段	匯入時就先整理成 wiki 頁面
基礎設施	向量庫 + embedding	只要資料夾 + agent
規模	可到大量文件	約 5 萬 ~ 10 萬 token 以內表現穩定，超過後 RAG 較有優勢
新增資料	上傳後自動索引，快	每份新來源都要 LLM 處理，有延遲與成本
跨文件綜合問題	較弱	較強
回答忠於原文	直接引用原文片段	引用的是 LLM 改寫過的摘要 <code>[atlan is-a</code>

為什麼客服 / 法律場景要小心

最大的問題是忠實度，wiki 頁面是 LLM 改寫過的內容，如果匯入時換重錯了，漏了例外條款，之

最大的問題是忠實度。Wiki 頁面是 LLM 以寫題的語言，如果輸入時摘要錯了一篇子例外條款，之後所有回答都會建立在錯誤之上，而且很難察覺。法律條文、產品規格、保固條件這類「一字不能差」的內容，風險比較高。你用的是本地 Qwen3.6-35B-A3B，整理品質也不會比大型雲端模型更穩。

另外，客服場景通常資料量會持續成長、更新頻繁，這正是 RAG 的強項。

建議做法

- 1. 原始文件永遠保留為唯一真相來源 (`raw/`)，wiki 只是它的整理層。
- 2. 回答時要求引用原文出處，必要時回頭核對 `raw/`，而不是只信 wiki 摘要。
- 3. 依場景選擇：
 - 資料量小 (幾十份文件以內)、重視跨文件整合與內部知識累積，例如內部研究或產品知識整理，用 llm-wiki，並由 Hermes Agent 負責維護。
 - 對外客服或法律諮詢、要求逐字準確、資料會擴充，繼續用 AnythingLLM 的 Query Mode。
 - 兩者想結合時，讓 AnythingLLM 的 workspace 同時索引 `raw/` 與 `wiki/`，用 wiki 做概覽、用原文做依據。

若想在 VM 內試做 llm-wiki

Hermes Agent 可以扮演維護 wiki 的 agent：

- 1. 建立資料夾 `knowledge/raw/`、`knowledge/wiki/`，以及一份 `schema.md`，寫明匯入、查詢、檢查三種操作的規則。
- 2. 把 Karpathy 的 Idea file 交給 agent，請它依你的領域產生 schema 與 `index.md`。
- 3. 丟一份文件進 `raw/`，請 agent 匯入，產出摘要頁並更新索引。
- 4. 在 schema 裡明確規定：只能根據 wiki 與 raw 內容回答，查無資料就明說，並附上來源檔名。
- 5. 定期請 agent 做 lint，檢查頁面之間的矛盾與過時內容。

要注意，Hermes Agent 有檔案與指令執行能力，若用於對外服務，要把它的可能寫範圍限制在知識資料夾內。另外 llm-wiki 本身是 agent 工作流程，不是現成的對外問答介面，客服前端還需要另外處理。

如果你的知識庫目前不大，我建議先用 AnythingLLM 跑通基礎版，再用同一批文件開一個小型 llm-wiki 實驗，比較兩邊的回答品質。你大概會處理多少份文件？這會影響我建議的取捨。

📄 建立試算表

🔗 🔊 🔍 🔄



+ 輸入訊息...

🔊 🔍 ~