

github +2

- 若你是第一次實作，建議先走 方案 A (ChromaDB)，熟悉流程後再升級到 qmd。

步驟 3：設定 Hermes 使用 ChromaDB 作為知識庫

在 VM 終端機執行：

```
bash

hermes config set knowledge_base_provider chromadb
hermes config set knowledge_base_path ./hermes_knowledge_base
```

- knowledge_base_path 是你指定的資料夾，ChromaDB 會在此儲存向量索引。 `agentupdate`
- 之後你可以用相對或絕對路徑，例如： `/home/youruser/hermes_kb`。

步驟 4：準備你的領域知識文件

1. 在 VM 內建立一個資料夾，例如：

```
bash

mkdir -p ~/kb_product_support
```

在電腦中作為獨立任務執行以獲得更佳結果
電腦運用更多工具與脈絡，產生更豐富的輸出。

執行任務 ↗

詢問後續問題

+

搜尋 ▾

電腦

模型 ▾

↕

↑

```
~/kb_product_support/
- faq.md
- product_manual.pdf
- policy_2025.docx
```

之後若要擴充，只要把新文件丟進這個資料夾，再重新索引即可。

步驟 5：將文件加入 Hermes 知識庫並建立索引

使用 Hermes 的文件指令（依官方範例）： `agentupdate`

```
bash

# 進入你想存放知識庫的目錄（可選，只是方便管理）
cd ~

# 將整個資料夾加入知識庫
hermes docs add ~/kb_product_support --name product_support_kb
```

在電腦中作為獨立任務執行以獲得更佳結果
電腦運用更多工具與脈絡，產生更豐富的輸出。

執行任務 ↗

詢問後續問題

+

搜尋 ▾

電腦

模型 ▾

↕

↑

```
bash

hermes docs index
```

（若你的版本沒有 `index` 子指令，通常 `docs add` 時就會自動處理。）

此時，ChromaDB 會在 `~/hermes_knowledge_base` 中建立向量索引。 `agentupdate`

步驟 6：設定 LLM 端點（接你的 LM Studio / Qwen）

你有兩個選擇：

選項 1：在 VM 內跑 Ollama / vLLM，再讓 Hermes 呼叫

- 優點：全部在 VM 內，架構單純。
- 缺點：要再安裝一個本地 LLM server。

選項 2：讓 VM 內的 Hermes 呼叫 Windows 上的 LM Studio API（推薦，充分利用你現有資源）

1. 在 Windows 上啟動 LM Studio 的本地伺服器

在電腦中作為獨立任務執行以獲得更佳結果
電腦運用更多工具與脈絡，產生更豐富的輸出。

執行任務 ↗

詢問後續問題

+

搜尋 ▾

電腦

模型 ▾

↕

↑

```
bash

curl http://<windows-ip>:1234/v1/models
```

若看得到模型列表，代表連線成功。

3. 在 Hermes 中設定模型提供者為 OpenAI-compatible

依 Hermes 文件設定 provider（不同版本指令可能略有差異，一般透過 `hermes config` 或編輯 `~/hermes/config.yaml`）：[hermes-agent.nousresearch +1](#) 範例（YAML 設定檔）：

```
text

provider: openai
api_base: http://<windows-ip>:1234/v1
api_key: not-needed
model: qwen3.6-35b-a3b
```

或透過指令（若支援）：

```
bash

hermes config set provider openai
```

 在電腦中作為獨立任務執行以獲得更佳結果
電腦運用更多工具與脈絡，產生更豐富的輸出。

執行任務 ↗

詢問後續問題

+

搜尋 ▾

電腦

模型 ▾ 🔊 ↶

你可以透過輸入相關的提示詞，例如：

1. 定義系統提示詞（system prompt），例如：

```
text

你是一個「產品客服專家」，只能根據提供的知識庫內容回答問題。
如果知識庫中找不到足夠資訊，請明確告知「目前知識庫中沒有相關資料」，不要自行推測或編造答案。
回答時盡量引用知識庫中的條文或段落（可用簡短說明來源文件名稱）。
```

2. 在 Hermes 中設定系統提示詞（依版本不同，可用 `hermes config` 或編輯 `config.yaml`）：

[hermes-agent.nousresearch](#) 範例（YAML）：

```
text

system_message: |
    你是一個「產品客服專家」，只能根據提供的知識庫內容回答問題。
    如果知識庫中找不到足夠資訊，請明確告知「目前知識庫中沒有相關資料」，不要自行推測或編造答案。
    回答時盡量引用知識庫中的條文或段落（可用簡短說明來源文件名稱）。
```

 在電腦中作為獨立任務執行以獲得更佳結果
電腦運用更多工具與脈絡，產生更豐富的輸出。

執行任務 ↗

詢問後續問題

+

搜尋 ▾

電腦

模型 ▾ 🔊 ↶

hermes chat

然後輸入與你的領域相關問題，例如：

- 「產品 A 的保固期限是多久？」
- 「根據內部規範，退貨流程是什麼？」

觀察：

- 回答是否基於你放入的文件內容。
- 若問與知識庫無關的問題，是否會說「知識庫中沒有相關資料」。

若效果不理想，可調整：

- 文件切塊大小（若 Hermes 提供相關設定）。
- 系統提示詞的嚴格程度。
- 檢索回的文件數量（top-k）。

 在電腦中作為獨立任務執行以獲得更佳結果
電腦運用更多工具與脈絡，產生更豐富的輸出。

執行任務 ↗

1. 建立多個知識庫集合

詢問後續問題

+

搜尋 ▾

電腦

模型 ▾ 🔊 ↶

每個集合對應一個「數位員工」人設。

2. 改用 `qmd skill` 支援多集合與更好檢索 [fast](#)

大致流程：

```
bash

# 安裝/啟用 qmd skill（依官方文件）
# 新增集合
```

```
qmd collection add ~/kb_product_support --name product
qmd collection add ~/kb_legal_consult --name legal
```

```
# 產生嵌入
qmd embed
```

```
# 在 Hermes 設定中使用 qmd 作為 MCP 工具
```

3. 為每個領域建立不同 **system prompt**，形成多個「客服 / 法務 / 技術支援」數位員工。



 在電腦中作為獨立任務執行以獲得更佳結果
電腦運用更多工具與脈絡，產生更豐富的輸出。

執行任務 ↻

你可以擁有這些：

詢問後續問題

+ 🔍 搜尋 🖨 電腦

模型 ▾ ⚙️ ⬆️

- ☐ 已建立知識庫資料夾（如 `~/kb_product_support`）並放入文件。
- ☐ 使用 `hermes docs add` 將文件加入知識庫。
- ☐ 確認 VM 可連到 Windows 上的 LM Studio API。
- ☐ 在 Hermes 設定好 OpenAI-compatible provider 指向 LM Studio。
- ☐ 設定好系統提示詞，限制只能依知識庫回答。
- ☐ 用 `hermes chat` 測試問答，確認行為符合預期。

如果你願意，我可以在下一步幫你：

- 依你實際的 Hermes 版本，寫出「可直接複製貼上」的完整指令腳本（含註解）。
- 或幫你設計一個「產品客服」與「法律諮詢」的系統提示詞範本，直接套用到你的知識庫。

      15 個來源 ...

➤ Build a local RAG pipeline for Hermes Agent in Linux: document chunking, vector indexing, and source-constrained retrieval rules  Computer

➤ Map out the RAG architecture for your Ryzen AI Max+ VM: comparing local vector stores (sqlite-vec vs ChromaDB) for 35B model inference  Computer

↳ 請幫我寫出可直接複製貼上的完整指令腳本

↳ 請提供產品客服與法律諮詢的系統提示詞範本

↳ 我想知道如何將 Qwen3.6 透過 LM Studio 的 API 串接給 Hermes

 在電腦中作為獨立任務執行以獲得更佳結果
電腦運用更多工具與脈絡，產生更豐富的輸出。

執行任務 ↻

詢問後續問題

+ 🔍 搜尋 🖨 電腦

模型 ▾ ⚙️ ⬆️